

CONTENIDO

Sometiendo a Estrés una Arquitectura Distribuida de Gobernanza de Recursos Públicos: Evidencia Adversarial y Conductual Basada en Agentes

Resumen

1. Introducción

2. Métodos: el marco de experimentación

3. Hallazgo 1: el ordenamiento es invariante a la población conductual, y la capa por defecto es existencial

4. Hallazgo 2: la calidad de asignación domina — y tiene dos capas

5. Hallazgo 3: la cuota atenta es estructural

6. Hallazgo 4: la pila de disuasión — individualmente redundante, conjuntamente indispensable

7. Hallazgo 5: la transición semi-abierta es un dial, no un salto

8. Hallazgo 6: la vista del pipeline — liberación, verificación, máquinas y adversarios

9. Hallazgo 7: la verificación por máquina medida — un panel real de cinco familias

9a. Hallazgo 8: el adversario colusivo — donde la historia de la verificación se rompe

10. Validación cruzada

11. Limitaciones y fronteras declaradas

12. Conclusiones

Declaración de reproducibilidad

Referencias

Stress-Testing a Distributed Public-Resource Governance Architecture: Adversarial and Behavioral Agent-Based Evidence

Sometiendo a Estrés una Arquitectura Distribuida de Gobernanza de Recursos Públicos: Evidencia Adversarial y Conductual Basada en Agentes

Borrador v0.7 (traducción) — 2026-07-07. Complemento del working paper "Distributed Resource Governance: An Architecture for Transparent Public Resource Allocation with Adversarial Validation" (doi:10.5281/zenodo.21193846), en adelante «el paper de arquitectura».

Resumen

El paper de arquitectura propone Core v0, una arquitectura de asignación de recursos públicos en la que la ciudadanía dirige cuotas de presupuesto hacia proyectos concretos bajo un desembolso condicionado por hitos y verificado de forma independiente, con la cuota que no participa absorbida por los perfiles de asignación de proyectos agregados sobre una categorización macro trazada por la autoridad o la sociedad. Este paper complementario reporta el programa de experimentación computacional que somete a estrés esa arquitectura más allá de su propia suite de simulación. Aportamos un marco adversarial reproducible basado en agentes (motores deterministas, semillas apareadas, diseños pre-registrados con contabilidad pública de predicciones, y un contrato de trazabilidad que vincula cada mecanismo con su anclaje arquitectónico), un método para generar participación conductualmente realista de forma endógena — incluida la calibración mediante priors elicitados por modelos de lenguaje de gran tamaño bajo una disciplina de estabilidad entre modelos — y ocho hallazgos. (1) La ventaja de la arquitectura sobre un status quo calibrado por auditoría (2.0–2.7× de valor verificado por unidad de presupuesto) es invariante entre poblaciones generadas conductualmente y alcanza su máximo bajo

baja adopción; la participación sin una capa por defecto no es más débil, sino que no funciona. (2) La calidad de asignación domina el valor entregado, y tiene dos capas que el motor previo había fundido erróneamente en un solo peso — una *categorización* macro (#1: una partición que no porta pesos de presupuesto, solo una alineación con el valor) y los *perfiles de asignación* de proyectos agregados (#2: ruteo dirigido-al-valor vs incidental-por-atributo); la construcción distribuida supera a la central en todas partes donde se cumplen sus precondiciones, y separar las capas (una corrección que forzó el trabajo terminológico) muestra que distribuir la categorización es irrelevante cuando el plan central está bien trazado, marginal con desalineación moderada (los perfiles mixtos se auto-corrigen, filtrando un ~7–10% acotado) y decisiva cuando es mayormente mala — así la ventaja de Core v0 sobre un status quo central no es fija sino que crece de $\approx 1.9\times$ a $\approx 5.7\times$ a medida que empeora la planificación central, siendo el arreglo distribuido robusto a una mala categorización y el central frágil a ella. (3) La proporción de ciudadanía que aporta señales explícitas de planificación es estructural (~2.5–5%) en todas las fuentes de priors. (4) La pila de disuasión es individualmente redundante y conjuntamente indispensable: remover cualquier término aislado no cuesta casi nada, remover todos ellos hace caer la arquitectura por debajo del status quo — un hallazgo que viajó de vuelta al canon de la arquitectura como una regla de integridad de despliegue. (5) La transición desde el status quo hacia la arquitectura completa es un dial, no un salto: un sobre presupuestario semi-abierto produce ganancias monótonas y casi lineales desde aproximadamente una cuota del diez por ciento hacia arriba. (6) Tratando el pipeline de forma dinámica, la política de liberación de presupuesto es una variable institucional real (el pull contra un techo de obra-en-proceso domina a la liberación por calendario), la capacidad de verificación es el techo del pipeline antes de ser el instrumento anti-fraude, la verificación por máquina actúa como seguro de capacidad cuyo laxo requisito de exactitud es *pagado* por la holgura de la pila de disuasión, y los adversarios adaptativos no erosionan ni invierten el ordenamiento mientras esa pila esté intacta. (7) Un panel real de cinco familias de modelos (Qwen, Gemma, DeepSeek en local; gpt-5.5, Claude alojados) mide la verificación por máquina de forma directa; tras una ronda interna de revisión que detectó un bug de constructo en el primer instrumento y su reconstrucción, el resultado corregido está escalonado por capacidad — los modelos de frontera convergen en buena especificidad y detección de fraude, los modelos locales pequeños son más débiles — con los dos modelos de frontera compartiendo un punto ciego medible, y las afirmaciones sobre independencia de ensemble, punto de operación y contraposición re-enunciadas como exploratorias o estipuladas con intervalos de confianza; la capa de máquina cubre únicamente el fraude document-legible («legible en el papeleo») de fase de entrega, no el robo de calidad física ni el precontractual. (8) Un adversario colusivo y multi-período es el primer ataque en mover la fuga en un orden de magnitud (~25 $\times$), porque elude la desigualdad de disuasión por hito — mientras que la ventaja de valor verificado sobrevive — acotando los hallazgos de verificación a un adversario no colusorio y convirtiendo la resistencia a la colusión entre capas en un requisito de primera clase. El docking entre marcos y las replicaciones internas entre motores respaldan los resultados de arquitectura (F1–F6); los hallazgos de verificación por máquina (F7–F8) son los menos maduros y se enmarcan en consecuencia. La evidencia de simulación no es prueba institucional; las fronteras se declaran a lo largo de todo el texto, y se reporta la propia segunda ronda de revisión adversarial de este paper, bug incluido.

1. Introducción

El paper de arquitectura pregunta si la tecnología actual permite un diseño de asignación de recursos públicos que mejore el modelo institucional vigente, y responde con una arquitectura — Core v0 — validada mediante revisión adversarial y una suite de simulación de ocho experimentos. Su objeto gobernado, y por tanto el nuestro, es la *porción discrecional con forma de proyecto* de un presupuesto público (obras de capital, subvenciones, programas locales) — no la nómina, las transferencias ni los servicios obligatorios. Esa suite establece el titular de la arquitectura bajo sus propios supuestos. Este paper ataca los supuestos.

Tres familias de preguntas requieren un programa computacional dedicado. Primero, **realismo conductual**: el paper de arquitectura impone cuotas de participación; ¿qué ocurre cuando la participación *emerge* de un proceso de adopción con fricción, rotación, prueba social y disposiciones heterogéneas? Segundo, **rendición de cuentas de los mecanismos**: cuáles de los mecanismos de la arquitectura sostienen los resultados, cuáles son redundantes, y dónde están los precipicios — preguntas que solo la ablación bajo presión adversarial puede responder. Tercero, **dinámica institucional**: la arquitectura especifica cómo se asigna, desembolsa y verifica el dinero, pero los despliegues reales también deben decidir *cuándo* se libera el presupuesto, *cuánta* capacidad de verificación financiar, y *qué ocurre a lo largo de los años* a medida que los adversarios se adaptan — variables que la suite estática no puede ver.

Responderlas requiere métodos que merecen reportarse por derecho propio: motores cuyo cada mecanismo está anclado a un documento arquitectónico publicado (un contrato de trazabilidad que hace auditable el «la simulación dice»), pre-registro con contabilidad pública de predicciones en la que las predicciones refutadas son hallazgos de primera clase, generación endógena de participación, y una vía de calibración que usa modelos de lenguaje de gran tamaño como *elicitadores sintéticos de priors* — nunca como oráculos — bajo una disciplina en la que solo los patrones estables entre modelos informan algo.

Contribuciones: (i) el marco (Sección 2); (ii) ocho hallazgos sobre la arquitectura (Secciones 3–9a), dos de ellos (verificación por máquina, el adversario colusivo) los menos maduros y enmarcados como tales; (iii) validación entre marcos y entre motores (Sección 10); (iv) un bucle de retroalimentación demostrado entre la simulación y el diseño institucional, en el que los hallazgos viajaron al corpus de la arquitectura a través de su pipeline adversarial como reglas de régimen de operación, de integridad de despliegue, de liberación presupuestaria y de paquete de verificación; y (v) dos rondas internas de revisión adversarial reportadas en su totalidad, la segunda de las cuales detectó y corrigió un bug de constructo en el hallazgo de verificación por máquina.

Todos los resultados son evidencia de simulación sobre un modelo de la arquitectura — no prueba institucional, no autorización legal, no validación de piloto. La Sección 10 recopila las fronteras declaradas.

2. Métodos: el marco de experimentación

Motores. Cuatro motores deterministas, todos con semilla (mulberry32 / `random` de Python), con sello de versión y anclados por regresión entre versiones: (A) un motor estático adversarial de comparación de arquitecturas (JavaScript, sin dependencias) que implementa cinco arreglos institucionales sobre un mundo de proyectos común; (B) un modelo conductual de adopción (Python; backend Mesa opcional, byte-idéntico en cualquiera de los dos casos) que genera poblaciones — conciencia, fricción de incorporación, actividad, rotación, formación de roles — bajo reglas conformes con Core v0; (P) un motor de construcción del vector de planificación que compara cómo se construyen los vectores de prioridad; y (E) un motor longitudinal de pipeline (v0.6–v0.8) que añade la política de liberación de presupuesto, llegadas de proyectos según Poisson, expiración de la ventana de financiamiento, ejecución multi-ciclo con escrow por hitos, capacidad de verificación acotada, dinámica de reputación de los ejecutores, carriles de verificación por máquina, ventanas de verificación y adversarios adaptativos. Cada directorio de resultados lleva un sello de metadatos (versión del motor, escenario, semilla, corridas); las actualizaciones de motor reproducen los anclajes previos de forma exacta (el anclaje longitudinal $V = 0.303844218531$ es bit-estable a lo largo de v0.6→v0.8; las líneas base comprometidas del motor estático son byte-idénticas a lo largo de v0.4→v0.5.1).

El contrato de trazabilidad. Cada mecanismo portante se mapea a su anclaje en el corpus de la arquitectura (la matriz de trazabilidad del repositorio): la regla de default público, el secreto de la asignación, reputación-informa-nunca-excluye, evidencia-gatilla-nunca-certifica, el desembolso condicional como la desigualdad formal de disuasión, los parámetros de status quo anclados en auditoría, y el vocabulario de régimen de operación. Los mecanismos sin anclaje se declaran o bien internos-al-experimento o se listan como brechas. Esto convierte la conformidad de una afirmación en un artefacto verificable.

Disciplina de comparación adversarial. Las arquitecturas se comparan sobre mundos idénticos (semillas apareadas; los mismos proyectos, sorteos de oportunistas y poblaciones ciudadanas enfrentan cada arreglo), bajo ataques (cascadas de saliencia, shocks de verificación débil, colusión de fiscalizadores, captura de agenda, sesgo coordinado de señales), contra un status quo calibrado según hallazgos publicados de instituciones de auditoría en vez de por conveniencia — incluyendo el régimen de control real del titular, no una caricatura opaca. La métrica primaria es el valor verificado por unidad de presupuesto (V): el valor social latente entregado, descontado por lo que la verificación independiente puede efectivamente confirmar.

Un compromiso normativo, nombrado. V presupone que el valor social a nivel de proyecto existe con anterioridad al mecanismo y puede ser descubierto y agregado — el vector de «valor social latente» que cada mundo sortea. Eso es una posición, no una neutralidad: la tradición deliberativo-constructivista, en la que el valor es *producido* por la contestación en vez de revelado por la agregación, queda fuera de este modelo, al igual que la redistribución, los derechos y la política expresiva que no toman la forma de entregables verificables. Los hallazgos sobre la «calidad informacional» de los constructores de planificación son hallazgos *dentro* de este compromiso; si el ordenamiento de la arquitectura sobrevive a un objetivo alternativo (un objetivo de cuota-mínima/Rawlsiano es la primera prueba natural) queda abierto y se nombra como trabajo futuro.

La privacidad individual de la asignación, un mecanismo portante referenciado a lo largo del texto, significa la privacidad estilo-voto de la asignación dirigida de cada ciudadano como dispositivo anti-coerción — los agregados, presupuestos, proyectos y cada acto institucional permanecen plenamente públicos.


Participación endógena (Experimento C). Las trayectorias emitidas por el modelo conductual — cuotas de actividad, elecciones de canal (directo, perfil, delegación, default), atención a la planificación — reemplazan los bloques de participación impuestos del motor estático a través de un mapeo publicado. La comparación de arquitecturas entonces se vuelve a correr bajo poblaciones que el proceso de adopción efectivamente produce, incluyendo un mundo de alta fricción y uno de delegación-primero.

Priors elicitedos por LLM. Donde los parámetros conductuales carecen de datos empíricos (disposición, preferencias de canal, aceptación de la delegación), elicítamos distribuciones desde paneles de modelos de lenguaje que interpretan veinte arquetipos ponderados por población, bajo tres reglas: el instrumento es idéntico al cuestionario humano que eventualmente lo reemplazará; la procedencia se registra como `llm-elicited`, una clase que no puede promoverse a empírica; y solo los patrones estables entre familias de modelos informan las conclusiones. Los límites de esa disciplina se enuncian con franqueza: la verificación entre familias (una familia local de pesos abiertos apareada contra una familia de frontera alojada) se ejercita en $n=90$; el panel $N=1,000$ portador de precisión es de una sola familia y por construcción no puede detectar su propia huella, así que su «convergencia hacia $n \approx 750$, deriva de composición ≤ 0.02 » es una afirmación de muestreo dentro-del-modelo, no una exactitud de calibración — una segunda familia a escala de frontera se nombra como trabajo futuro. La suficiencia de la media (usar las medias elicítadas en vez de las distribuciones completas aguas abajo) se probó, no se asumió: el análisis comprometido de distribución-versus-medias encontró los resultados aguas abajo insensibles al colapso a estos tamaños de muestra, con las corridas distribucionales de semilla fija como verificación.

Pre-registro, con su verificabilidad enunciada con honestidad. Los diseños con predicciones nombradas se escribieron antes de las corridas en todo el programa, pero la garantía *verifiable-por-git* varía y la enunciamos en vez de difuminarla: los diseños E-1a y E-1c se comprometieron por separado, minutos antes de sus corridas (verificable de forma independiente desde el historial); los diseños de ablación y E-1b se comprometieron atómicamente con sus resultados (escritos primero, pero no probables por separado); la cuantificación semi-abierta se corrió sin un archivo de diseño autónomo y se clasifica como exploratoria. Un registro de predicciones legible por máquina (`predictions.csv`: predicción → fuente → resultado) acompaña al repositorio. De veintitrés predicciones registradas, ocho fueron refutadas o nulas en rango y una se transformó materialmente — cada una reportada como un hallazgo, varias de ellas los resultados más informativos de su fase.

3. Hallazgo 1: el ordenamiento es invariante a la población conductual, y la capa por defecto es existencial

Bajo cuatro poblaciones generadas conductualmente (línea base sintética, calibrada por LLM, alta fricción, delegación-primero) más los bloques impuestos originales, el ordenamiento nunca cambia: Core v0 con una agenda distribuida entrega 2.05–2.69× el valor verificado por unidad de presupuesto del status quo (los intervalos apareados al 95% excluyen el cero en todas partes; la dispersión del ratio entre semillas-base es de 2.19–2.28× en la población calibrada — anexo estadístico).



Valor verificado por unidad de presupuesto entre las cinco arquitecturas bajo poblaciones impuestas y conductuales (media $\pm$ DE, 20 corridas apareadas). El ordenamiento es invariante a la población; la variante participativa sin default colapsa a cero bajo cada población conductual.

! [Ratio de valor verificado de Core-distribuido a status quo por población. La ventaja alcanza su máximo bajo alta fricción — la baja adopción encauzada a través de un default bien construido es el mejor caso de la arquitectura.] (./figures/expc_core_advantage.png) Dos resultados estructurales yacen bajo los ratios. Primero, la ventaja *alcanza su máximo bajo baja adopción* (alta fricción: 2.69×): la pasividad encauzada a través de la capa por defecto es el mejor caso de la arquitectura. La condición que sostiene ese resultado contraintuitivo debe nombrarse: se cumple porque los perfiles por defecto están *bien alineados* — su calidad informacional es exógena en estos mundos (mezcla de señales 0.66 bajo la frontera de señal-honesta) — y el barrido de la ablación pone precio a la dependencia: degradar la mezcla a 0.2 atenúa la ventaja a 1.63× (nunca por debajo de ella), mientras que la elicitación honesta bajo gaming sigue siendo el problema abierto declarado de la arquitectura. La baja adopción es el mejor caso *dado un default bien construido*, no incondicionalmente. Segundo, la variante participativa sin una capa por defecto — el arreglo que la mayoría de los despliegues de civic-tech construyen implícitamente — colapsa a **cero entrega verificada bajo cada población realista**: con 3–6% de participación activa y sin regla de absorción, los proyectos nunca alcanzan los umbrales de financiamiento. La participación sin una capa por

defecto no es una arquitectura más débil; es una que no funciona. La lección de diseño es incómoda y cuantificada: la poca glamorosa regla por defecto, no la funcionalidad de participación, es lo que hace de la asignación ciudadana una institución en vez de una encuesta.


4. Hallazgo 2: la calidad de asignación domina — y tiene dos capas

La calidad informacional con que el presupuesto llega a proyectos que portan valor es la palanca dominante sobre el valor entregado. El programa de construcción compara constructores según su correlación con el valor social latente: la familia de canales de Core v0 (señales de ciudadanía atenta + delegadas, voluntarias u obligatorias) abarca 0.815–0.939; la construcción central representativa (planificadores coherentes, limitados en ancho de banda, guiados por saliencia, de la legitimidad de crisis a la alta alineación) abarca 0.315–0.650; la saliencia pura alcanza 0.187. Las familias no se solapan: **el peor canal distribuido supera en información al mejor régimen representativo** — donde se cumplen sus precondiciones declaradas (existe una institución de agregación; las señales son honestas y sin sesgo), siendo la elicitación honesta bajo gaming el problema abierto permanente. En el motor fusionado de peso único esta brecha era el término dominante: reemplazar la construcción distribuida por una central era el mayor knockout de un solo mecanismo ($\Delta V -0.062$), y barrer la calidad de construcción movía la ventaja de $1.63\times$ a $2.35\times$ — la mayor palanca de cualquier parámetro individual.

Ese «vector de planificación» era, sin embargo, un único peso fusionado que confundía dos objetos institucionalmente distintos — y esa confusión fue en sí misma un hallazgo. Afinar la terminología (una nota canónica ahora la gobierna) forzó una corrección del modelo, porque un tercero leyendo el motor malinterpretaría la arquitectura. Los dos objetos son: (#1) la **categorización macro** — una partición de tipos de proyecto elegibles que traza la autoridad o la sociedad, que *no* porta pesos de presupuesto, cuya única calidad es qué tan bien sus categorías se alinean con el valor latente; una partición central puede admitir categorías desalineadas (de bajo valor) que una distribuida excluiría. Y (#2) los **perfiles de asignación de proyectos** — las reglas ponderadas con que la cuota de cada ciudadano llega a proyectos concretos, con reglas dirigidas al valor («educación parvularia rural») e incidentales por atributo («proyectos cerca de mí»). Lo que gobierna la entrega es la *agregación de los perfiles de la mayoría desatendida*, no un vector macro. El motor fusionado es exactamente la reducción a una categoría del modelo de dos capas y lo reproduce bit-a-bit (el anclaje se mantiene exacto con la feature apagada), así que los números previos quedan como forma reducida — y el motor de dos capas (Experimento H) hace lo que el fusionado no podía: **separar las dos palancas y mostrar cómo se componen**.

El resultado es una *transición*, no una constante. Distribuir la categorización (#1) es **irrelevante** cuando la autoridad traza categorías bien alineadas (ambas particiones entregan igual), **marginal** con desalineación moderada (los perfiles mixtos de los ciudadanos rutean alrededor de las categorías malas, y solo la fracción incidental por atributo filtra — un $\sim 7\text{--}10\%$ acotado del presupuesto), y **decisiva** cuando la categorización es mayormente mala (los buenos proyectos ni siquiera son elegibles, y #2 no puede rutear hacia lo ausente). Bajo distribución, el valor entregado es **robusto** a la calidad de la categorización central; bajo planificación central es **frágil** a ella. Comparando arquitecturas, esto vuelve la ventaja de Core v0 sobre un status quo central *no fija* sino

función de la calidad de la planificación central: sube de $\approx 1.9\times$ (categorización bien trazada) a $\approx 5.7\times$ (**mayormente mala**) porque se componen dos efectos — la *ventaja de elegir* (#2 rutea el presupuesto a proyectos de mayor valor) y *evitar la imposición de un mal plan central* (#1 re-categoriza en vez de quedar atrapado en las categorías de la autoridad). El modelo fusionado no podía expresar ninguno; el de dos capas muestra ambos. Políticamente: adoptar el arreglo distribuido protege el valor entregado *aunque el planificador se equivoque* — el valor de distribuir es mayor justo donde la planificación central es peor.



Escala de calidad del vector de planificación: correlación con el valor social latente por constructor. La familia de canales de Core v0 (banda superior) no se solapa con la familia central representativa; la de solo-salience se sitúa al fondo.

5. Hallazgo 3: la cuota atenta es estructural

Tanto entre escenarios de adopción como entre fuentes de priors, la proporción de ciudadanía que aporta señales explícitas de planificación se mantiene acotada en dígitos individuales bajos: el rango comprometido, 2.5–5.1%, es la dispersión *entre escenarios de adopción* (2.5% bajo alta fricción hasta 5.1% bajo incorporación asistida por IA), y cada fuente de priors — disposiciones sintéticas, los paneles apareados de $n=90$, el panel ponderado de $N=1,000$ — cae dentro de él. La atención se mueve con el contexto de adopción dentro de esa banda pero nunca escapa de ella: una disposición acotada, no un resultado de involucramiento escalable. Dos notas epistémicas antes de las consecuencias. La concordancia entre los priors sintéticos y los elicitados por LLM **no** es validez convergente — ambas son fuentes no empíricas con procedencia solapada — así que dentro del

programa este resultado mantiene el estatus de una hipótesis en espera del instrumento humano idéntico. Su referente externo es en cambio el registro de campo del presupuesto participativo: tres décadas de despliegues de PP reportan tasas de participación activa en dígitos individuales bajos de la población elegible (los años canónicos de Porto Alegre, las encuestas transnacionales recopiladas por Sintomer y colegas, y las comparaciones brasileñas de Wampler), la misma banda que el modelo produce de forma endógena — mientras que la polis simulada omite lo que la literatura de campo muestra que *mueve* esas tasas: la movilización partidaria, los ciclos de campaña y la concurrencia de grupos organizados, nada de lo cual se modela más allá de un parámetro escalar de intensidad de campaña. Lo que el hallazgo entonces dice es condicional y útil: los diseños que requieren más que una atención espontánea de un solo dígito están apostando contra el modelo y contra el registro de campo a la vez.

Tres consecuencias. Primero, los diseños de la capa de planificación deben funcionar con atención de un solo dígito — y lo hacen: la calidad del vector distribuido sobrevive porque la delegación y los defaults agregan la información de la minoría atenta. Segundo, la cuota informada impuesta del paper de arquitectura (0.30 de los participantes) es conductualmente realizable: el proceso de adopción calibrado por LLM produce 0.309 de forma endógena, y el propio experimento E8 del paper de arquitectura confirma que el titular sobrevive a la participación conductual en $2.26 \times [2.23, 2.30]$ frente a $2.22 \times$ impuesto — ambos números registrados en los resultados-de-simulación del repositorio *maestro* (§E8), citados aquí como evidencia externa: E8 consume las poblaciones de este programa pero corre, y es reproducible, en ese repositorio, no en este. Tercero, la restricción vinculante del lado del control no es la adopción sino el mercado de verificación — anticipando el Hallazgo 6.

6. Hallazgo 4: la pila de disuasión — individualmente redundante, conjuntamente indispensable


La ablación pre-registrada eliminó cada mecanismo. Los términos de disuasión caen en un patrón distintivo: remover la intensidad de detección, los términos financieros o la memoria reputacional *de forma individual* cuesta ≤ 0.003 V — en el punto de operación diseñado la desigualdad de compatibilidad de incentivos se cumple con holgura, así que cada término individual parece inútil al margen. Remover la **pila completa** colapsa el valor verificado en un 60% y hace caer la arquitectura **por debajo del status quo (0.87×) con su calidad de selección intacta**: la selección distribuida no puede compensar una entrega no verificable. La amenaza institucional no es un atacante sino un implementador que negocia concesiones defendibles una a una; el hallazgo viajó a través del pipeline adversarial de la arquitectura (ataque A041) y se resolvió en su canon como una regla de integridad de despliegue — cada ámbito publica su margen de desigualdad-de-disuasión, recalculado en cada cambio de término, con las reducciones de términos clasificadas como cambios materiales de regla.

El programa de ataques afinó el cuadro. La colusión de fiscalizadores a tasas plausibles es *neutralizada* por la holgura de la pila (el término de anticipación-de-colusión del modelo formal hecho visible). El sesgo coordinado de asignación entre ciudadanía atenta cuesta ≤ 0.007 a una cuota coordinada del cincuenta por ciento. El único ataque que muerde — la captura de un vector

de planificación publicado (−13% de valor, −35% de calidad de selección a alta severidad) — presupone un punto de estrangulamiento de publicación que existe solo en el régimen tutelado-con-agenda-obligatoria; la construcción distribuida no tiene tal superficie, y su análogo (corrupción de señales) es el caso robusto. La propia doctrina de régimen de la arquitectura absorbió esta lectura: poner precio a la captura es un argumento *a favor* de la construcción distribuida de la agenda, no en contra de la arquitectura. Finalmente, la ventaja *crece* con la suciedad del pool de ejecutores (2.39× con 70% de oportunistas): cuanto más sucio el entorno, más valen los controles.

7. Hallazgo 5: la transición semi-abierta es un dial, no un salto

La escalera de régimen de operación de la arquitectura define un régimen semi-abierto: un sobre presupuestario acotado en piloto automático de protocolo junto al presupuesto tradicional de la autoridad. Su primera cuantificación, como una mezcla fiscal sobre pools de proyectos disjuntos: el valor verificado mezclado sube de forma monótona y casi lineal con la cuota del sobre — punto de equilibrio cerca de 8–10%, 1.52× a la mitad del presupuesto, 2.18× al completo — con una única caída al cinco por ciento causada por la granularidad de cartera de dos-proyectos, no por el régimen. El sobre alcanza la calidad de arquitectura-completa desde aproximadamente una cuota del 35%; lo que crece a partir de ahí es la proporción de presupuesto que la disfruta. Para la política de adopción esta es la forma más amigable posible: sin valle, sin umbral, cada incremento rinde, y el sobre mínimo sensato lo fija la diversificación de cartera, no la fe.



La senda de transición semi-abierta: valor verificado mezclado por presupuesto a medida que la cuota del sobre barre de 0–100%, contra la referencia del status quo. Un dial, no un salto.

8. Hallazgo 6: la vista del pipeline — liberación, verificación, máquinas y adversarios

El programa longitudinal (Experimento E) hace real el tiempo: se liberan presupuestos, los proyectos llegan y expiran, la ejecución toma ciclos bajo escrow por hitos, la verificación tiene capacidad acotada, la reputación se acumula, los adversarios se adaptan.


Política de liberación (E-1a). El calendario de liberación de la autoridad — una variable que ningún documento arquitectónico reguló — importa institucionalmente. La liberación en día-cero congela 5.2 meses de presupuesto en escrow de ejecución con la cola de verificación saturada; la liberación mensual uniforme (el default implícito de la mayoría de la presupuestación pública) maximiza la mortalidad de proyectos por expiración de la ventana de financiamiento; liberar contra un **techo de obra-en-proceso** (una política pull) domina la frontera de Pareto en $W \approx 7$ meses de presupuesto. El mecanismo es la Ley de Little: $WIP\text{ saludable} \approx throughput\text{ alcanzable} \times tiempo\text{ de ciclo}$, y W sigue al recurso vinculante — la capacidad de verificación cuando es escasa, la duración de ejecución cuando es abundante. La liberación por retroalimentación condicionada al flujo de aprobaciones recientes rinde por debajo (0.269 vs 0.304); la variable de condicionamiento correcta es el stock de compromisos pendientes, que es lo que el pull implementa. Bajo capacidad de verificación escasa, ninguna política recupera el techo ($V \leq 0.255$) y la sobre-liberación destruye valor activamente (0.236) — **la capacidad de verificación es el techo del pipeline antes de ser el instrumento anti-fraude.**

Una salvedad de finanzas públicas pertenece al texto principal, no a una nota al pie: la tesorería del modelo no caduca, mientras que la mayoría de los regímenes de asignación presupuestaria imponen la anualidad del año fiscal. La regla de liberación se enuncia por tanto *condicionada a un instrumento de arrastre* — un fondo de capital, un fondo rotatorio o un programa de inversión plurianual; el sobre semi-abierto de la arquitectura es precisamente un vehículo así — y bajo anualidad estricta degenera a un pull dentro-del-año. Una variante de E-1a con fondos que caducan y encumbramiento explícito está pre-comprometida como la próxima corrida de motor.

Verificación por máquina (E-1c). Modelar un verificador de IA como un sistema de triaje (auto-liberación para clases de evidencia protocolizables, derivación-con-dossier, muestreo humano incondicional) con el acoplamiento de disuasión hecho explícito — los oportunistas sofisticados anticipan la probabilidad de detección de extremo a extremo — arroja tres resultados. A capacidad escasa, el triaje eleva el techo que ninguna política de liberación pudo ($0.254 \rightarrow 0.316$). El cruce de exactitud pre-registrado *nunca aparece* hasta una tasa de falso-pase del 20%: el efecto dossier y la holgura de la pila de disuasión absorben el error del verificador, así que el requisito de exactitud para un verificador por máquina útil es notablemente laxo — **condicionado a una pila intacta**. Y el rol vinculante del carril de muestreo humano es epistémico (medir la tasa de error real de la máquina), no tapar fugas. Las ventanas de verificación abordan una falla distinta: la falta de respuesta del fiscalizador cuesta hasta el 38% del valor entregado, y un timeout de un ciclo con reasignación automática recupera ~80% de él; los timeouts arreglan la cola, nunca el techo.

Adversarios adaptativos (E-1b). La diversión sincronizada con la congestión bajo obsolescencia de la evidencia, el gaming de evidencia contra el carril de máquina hasta habilidad 0.55, y ocho años de dinámica mueven todos el valor verificado dentro del ruido en la configuración intacta; la regla

pull elimina de plano la superficie de ataque de congestión (backlog demasiado corto para que la evidencia se vuelva obsoleta), e incluso en una falla conjunta diseñada (capacidad escasa + liberación en día-cero, cola de treinta) el adversario consciente del tiempo gana solo fracciones de fuga. Sobre una pila **rota**, cada arreglo de verificación — humano, máquina, máquina con gaming — aterriza dentro del ruido del mismo colapso ($V \approx 0.114\text{--}0.118$): *la verificación está aguas abajo de la disuasión; nada en la capa de verificación compensa un piso de incentivos roto*. La composición de reputación a lo largo de ocho años es nula en rango: la ventaja es plana y robusta desde el primer ciclo, porque una pila que disuade desde el inicio nunca se demora en el margen donde la memoria se compondría. El cierre institucional del programa cabe en tres líneas: **dimensiona la capacidad; dosifica la liberación; protege el margen**.



Políticas de liberación E-1a: valor verificado por año-presupuesto (izquierda) y obra-en-proceso congelada en meses de presupuesto (derecha) a lo largo de la grilla de políticas. La familia pull domina el trade entre valor y congelamiento.

El problema de desplazamiento del verificador y su frontera (E-1d). Un verificador por máquina de precio casi-cero es una *amenaza de desplazamiento* para el mercado de fiscalizadores humanos cuyo muestreo es la única auditoría de la máquina: colapsa tanto el costo de la fiscalización como el incentivo a fiscalizar, y con ello la capa epistémica que mide a la máquina. La respuesta de diseño, registrada en el corpus de la arquitectura y evaluada aquí, coloca a los humanos permanentemente como la **segunda instancia** — una capa de auditoría obligatoria financiada por un piso publicado de presupuesto-de-control (los ahorros de la máquina se re-asignan a sus propios auditores; un complemento por regla, no un competidor en precio). La frontera de cobertura es **exposición universal, inspección selectiva**: cada desembolso enfrenta una probabilidad publicada no nula de revisión humana de segunda instancia, y el conjunto obligatorio (de probabilidad-uno) comprende las clases de evidencia no protocolizables, los montos por encima de un umbral publicado por ámbito, los ejecutores con historiales delgados, las anomalías marcadas por la máquina, las revisiones gatilladas por denuncia, y las ventanas posteriores a un cambio de modelo. La evaluación E-1d entonces corrigió la propia epistemología del diseño: con una pila de disuasión intacta, un verificador que deriva del 5% al ~95% de falso-pase cuesta casi nada ($V \sim -0.002$) y *el muestreo pasivo nunca lo detecta* — los verdaderos positivos casi-nulos hacen la tasa de falso-pase inmedible a cualquier tasa de muestreo asequible. Cuanto más sano el sistema, más ciega su auditoría de resultados. El instrumento epistémico de la frontera es por tanto **controles positivos sembrados** — sondas de violación-conocida inyectadas en el carril de máquina a una tasa q , que

dan una latencia de detección de deriva $\propto 1/(q \cdot \pi)$ independiente de la tasa de diversión real disuadida — mientras que el piso aleatorio `s_min` sirve a la exposición, las apelaciones y la óptica de disuasión. La revisión humana de segunda instancia está así *siempre activa* como exposición estadística y sondeo sembrado para cada proyecto, y *siempre total* solo dentro del conjunto obligatorio.

9. Hallazgo 7: la verificación por máquina medida — un panel real de cinco familias

Los resultados de verificación por máquina del Hallazgo 6 usaron tasas de error estipuladas; el programa F las midió sobre cinco familias reales de modelos — Qwen3.6-35B, Gemma 4-26B y DeepSeek-R1-14B corriendo en local; gpt-5.5 y Claude alojados — juzgando viñetas de evidencia de verdad-terreno comprometidas antes de cualquier corrida, puntuadas por máquina, con el decoding divulgado por familia (no pueden uniformarse; la comparación es familia + decoding recomendado, no una comparación controlada de sampler, así que las afirmaciones entre familias se tratan como exploratorias). Esta sección fue **reconstruida tras una ronda interna de revisión que encontró un bug de constructo** en su primer instrumento, y la corrección cambió el titular; reportamos el resultado corregido y el bug, porque la corrección es en sí misma la parte más instructiva.

El bug, y por qué importa. El primer instrumento de «fraude sutil» adjuntaba, a cada paquete *limpio*, una línea de factura por encima del umbral de aprobación que el propio paquete publicaba — sin registro de aprobación. Los modelos que marcaban esos paquetes estaban *en lo correcto*; puntuados contra una etiqueta «limpia», se registraban como falsas alarmas. Esto invirtió el resultado aparente: gpt parecía un gatillo-fácil de 80%-falso-flag cuando en realidad estaba atrapando una violación de control real que la etiqueta negaba. Sobre un instrumento des-filtrado (cada monto por encima del umbral lleva una aprobación adecuada; el fraude de estructuración-entorno-al-umbral sigue siendo el que divide ítems *por debajo* del umbral para evadirlo), el cuadro es distinto y más limpio.

Resultado corregido: los modelos de frontera convergen en buena especificidad; los modelos locales pequeños son más débiles. En fallas verificables mecánicamente cada familia atrapa esencialmente todo (correlación no comprobable, declarada). En fallas que requieren juicio, con intervalos IC 95% de Wilson:

familia (escala/host)	falso-pase, fraude sutil [IC 95%]	falso-flag, trabajo limpio [IC 95%]
gpt-5.5 (frontera, alojado)	0.083 [0.036, 0.181]	0.033 [0.009, 0.114]
Claude (frontera, alojado)	0.083 [0.036, 0.181]	0.083 [0.036, 0.181]
Gemma 4-26B (local)	0.200 [0.116, 0.324]	0.265 [0.162, 0.403]
DeepSeek-R1-14B (local)	0.200 [0.118, 0.318]	0.567 [0.441, 0.684]
Qwen3.6-35B (local)	0.000 (no aprueba nada)	0.981 [0.899, 0.997]

Los dos modelos de frontera tienen buena especificidad y detección de fraude estadísticamente similares (≈ 0.08 en ambos ejes); los modelos locales pequeños son materialmente más débiles en ambos; Qwen es degenerado bajo este prompt (negar-todo). **La «dispersión de temperamento de 6× entre familias» de la v2 y el «rescate por riqueza de evidencia» eran artefactos de filtración y se retiran** — con un instrumento justo, gpt no es un gatillo-fácil. La lectura honesta entre familias está escalonada por capacidad (frontera vs local-pequeño), no es un ordenamiento de temperamento de cinco vías, y el confundido familia/decoding se divulga en vez de descartarlo con una afirmación.

La correlación es exploratoria y con poca potencia — con una señal real. Los conteos conjuntos de falso-pase son 0–4 eventos, así que cada ϕ por pares y cada ratio de ensemble se reporta con una salvedad y un IC bootstrap, no como una estimación resuelta. De diez apilamientos-de-dos, dos tienen un intervalo de ratio bootstrap estrictamente por encima de la predicción de independencia; el más claro es el **par de frontera gpt–Claude ($\phi=0.78$, Fisher exacto $p<0.001$, ensemble 9.6× peor que la independencia [4.7, 30])** — una señal genuina de punto-ciego-compartido entre los dos grandes modelos alojados, exactamente la dependencia que hace que el ingenuo «solo agrega un segundo modelo» prometa de más. El q efectivo de causa-común es pequeño (≈ 0.02 – 0.06); el pre-registrado «el ensemble falla peor que la independencia» se sostiene direccionalmente pero a $n\approx 60$ no puede respaldar los multiplicadores de dos cifras significativas que la primera versión citó. En el motor de pipeline, una segunda capa rinde solo contra el fraude de error-independiente ($k^*=2$, el beneficio desaparece hacia $q=0.3$) y multiplica las derivaciones honestas.

Los puntos de operación son orientables — la versión verdadera de una afirmación que el bug había corrompido. Con la filtración removida, la historia de «la riqueza de evidencia rescata a Claude 95%→5%» desaparece (era el artefacto). Lo que sobrevive es la afirmación más débil y defendible: una sonda de calibración movió la tasa de falso-flag de gpt solo por instrucción a un costo de recall, así que los puntos de operación son condicionales al prompt, y los contratos de evidencia que incluyen referencias de comparación objetivas (benchmarks de mercado, bandas de duración, umbrales) permiten a un verificador estricto juzgar en vez de adivinar. Esta es una hipótesis respaldada por la sonda, no una medición controlada dentro-del-instrumento.

Alimentar puntos medidos en el pipeline (F-3) — reetiquetado como una sensibilidad, no una medición. Inyectar el punto de operación medido de la peor-familia (~ 0.20 de falso-pase) en el motor longitudinal, sobre una pila de disuasión intacta, la fuga se mantiene indistinguible de la verificación puramente-humana, porque la cascada remueve los *intentos* aguas arriba; y ningún verificador rescata una pila rota. Los otros parámetros de verificación del motor (cuota protocolizable, tasa de muestreo, refuerzo por dossier) son estipulados, no medidos, así que F-3 es una sensibilidad de mecanismo-estipulado en torno a la exactitud medida, no una medición de extremo a extremo. La lectura institucional se sostiene: los modelos imperfectos de hoy bastan en la capa de verificación *siempre que la cascada de incentivos esté intacta y el adversario sea no colusorio* (Sección 9a).

Evidencia ciudadana contrapuesta (F-4) — un barrido de mecanismo-estipulado, fuerte pero acotado. Los productores de evidencia independientes con intereses opuestos al ejecutor, cuya contradicción anticipada disuade la diversión, se modelan con una tasa de captura estipulada y una cobertura barrida (no medida): la fuga cae abruptamente con la cobertura sobre la pila intacta, y el

instrumento es el único que rescata sustancialmente una pila *degradada* — pero ese rescate es una cota superior que asume que la capa de contribuidores es genuinamente independiente, lo que la Sección 9a muestra que un anillo colusorio borra. La revisión humana entonces se concentra donde las máquinas discrepan, la confianza es baja, los montos son altos, la evidencia se contradice, o el piso aleatorio se dispara; la cuota resultante de toque-humano (ligera, asistida por dossier) está acotada por debajo por el conjunto obligatorio, que sobre una cartera real *ponderada por valor* es probablemente una fracción mayor de lo que sugiere una estimación por conteo-de-proyectos — así que la cifra de «70–85% menos de trabajo de verificación» se enuncia sobre la base de la capa-verificable-por-documento, por conteo-de-proyectos, y se marca como una sobrecuenta de la reducción ponderada por valor.

Alcance (lo que la capa de máquina no puede alcanzar). Cada resultado aquí es sobre el fraude *document-legible, de fase de entrega*. El fraude más costoso de las obras públicas no está en el paquete de evidencia en absoluto: la colusión precontractual y el sobreprecio roban antes del primer hito; la calidad-bajo-especificación (hormigón al 60% de resistencia, materiales sustituidos tras superficies terminadas) se fotografía perfectamente y solo se atrapa mediante ensayos físicos; el fraude de cantidad es la brecha entre un registro consistente y el mundo. «Court-grade por construcción» exageró la procedencia atestiguada — la afirmación exacta es *evidencia-de-manipulación y con procedencia atestiguada en la captura*, con la cadena de custodia, la contradicción y el testimonio pericial todavía requeridos para la admisibilidad y el peso. La verificación por máquina y ciudadana cubren la capa de documentos; las capas física y precontractual permanecen plenamente humanas.

9a. Hallazgo 8: el adversario colusivo — donde la historia de la verificación se rompe

Los Hallazgos 6–7 (E-1b, F-3, F-4) sortearon la decisión de diversión **una sola vez**, como una apuesta de valor esperado contra la probabilidad de detección publicada, con las capas de verificación puestas a precio como sorteos independientes cuyas protecciones *se multiplican*. Un adversario real es multi-período y colusivo. El Experimento G modela un anillo que controla, sobre una cuota de hitos, al ejecutor *y* a sus verificadores *y* a sus contribuidores de evidencia ciudadana — así que para esos hitos los resultados entre capas los fija el anillo (diverge, sus verificadores dan el visto bueno, sus contribuidores permanecen callados), y la protección es el **mínimo, no el producto**.

El resultado es el primer ataque en todo el programa en mover la fuga en un orden de magnitud: a tasas de colusión de 0 a 50% la fuga sube $\sim 25\times$ ($0.0021 \rightarrow 0.052$), donde cada ataque de un-solo-instrumento del Hallazgo 6 la movía en menos de $2\times$. También **reduce a la mitad el rescate por contraposición de F-4** (los hitos coludidos no producen contradicción, así que el enrutador no convoca a ningún humano). Dos hechos van juntos y ambos son el hallazgo: la fuga sube abruptamente, y aun así la ventaja de *valor verificado* sobre el status quo sobrevive todo el rango ($2.72\times \rightarrow 2.56\times$), porque la mayoría honesta sigue cargando la entrega — así que la historia de seguridad vive en la columna de fuga, no en el ratio de valor, una distinción que los hallazgos anteriores centrados en el valor oscurecían. El apuntado adaptativo al punto ciego y el

envenenamiento de la referencia de precio exógena son reales pero acotados sobre una pila intacta (todavía se enrutan a través de la desigualdad por hito); la colusión es peligrosa precisamente porque no lo hace.

La consecuencia, ahora en el corpus de la arquitectura (docs/113): la resistencia a la colusión entre capas es un requisito de primera clase, no una precaución residual — titularidad beneficiaria verificada para que un anillo no pueda ciclar sociedades pantalla, resistencia-Sybil en la capa de contribuidores para que la cobertura de contraposición no pueda ser astroturfeada ni silenciada, y descentralización del asignador/sembrador/fijador-de-piso para que un anillo no pueda enrutar su fraude a su propio revisor capturado. Los Hallazgos 6–7 quedan por la presente acotados a un adversario **no colusorio**; el caso colusivo es la frontera que este programa alcanzó pero no cerró, y la forma más profunda de la propia salvedad permanente del paper — este es un modelo de adversario de autor único, y la independencia que falta es un segundo autor para el adversario.

10. Validación cruzada

Docking entre marcos. Una reimplementación independiente en Python nativo-Mesa de la comparación estática de arquitecturas (lenguaje, paradigma y RNG distintos — Mesa 3.5.1 con el `random` de Python, frente a JavaScript sin dependencias con `mulberry32`; equivalencia evaluada distribucionalmente según el estándar de docking de Axtell et al.) reproduce la comparación de cinco arquitecturas sobre la población calibrada por LLM en **15/15 PASS** (cinco arquitecturas $\times$ tres métricas, cada $|\Delta_{\text{media}}|$ dentro de dos errores estándar combinados): valor verificado por presupuesto 0.2780 vs 0.2774 para el brazo de agenda-distribuida, concordancia exacta cero–cero en el colapso sin-default, y distribuciones coincidentes de fuga y de correlación-de-selección en todo el recorrido (`docking/DOCKING_REPORT.md`). La mayor divergencia residual se divulga en vez de promediarla y hacerla desaparecer: la celda de status quo del dock aterriza en 0.1345 frente al 0.1267 de la referencia — dentro de la banda ($|\Delta|$ 0.0077 vs 0.0114), pero suficiente para mover el ratio titular del lado-del-dock a $\approx 2.07\times$ frente al $2.19\times$ de la referencia. La afirmación de docking es por tanto ordinal y distribucional: mismo ordenamiento, misma estructura de colapso, ratios coincidiendo dentro de un $\sim 5\%$ — no ratios decimal-idénticos. El criterio de equivalencia (dos errores estándar combinados por celda) se fijó en el brief de docking antes de que corriera el port; un margen TOST pre-especificado es la mejora nombrada para la revisión.

Docks internos entre motores. Tres replicaciones a través de motores estructuralmente distintos: la celda de pila-degradada del motor longitudinal ($V = 0.114$, fuga 0.057) reproduce la celda de knockout-conjunto de la ablación estática (0.110, 0.053); el E8 del paper de arquitectura, consumiendo las poblaciones conductuales de este programa en su propio motor, reproduce su titular de participación-impuesta (2.26 vs 2.22); y la cuota atenta emergente (Experimento B) aterriza dentro del rango que el programa del vector de planificación había asumido de forma independiente.

Estadística. Comparaciones apareadas-por-semilla en todo el texto; el anexo reporta intervalos t al 95% e intervalos de ratio de Fieller/bootstrap — cada diferencia apareada y cada ratio titular excluye su nulo — más la declaración de comparaciones-múltiples sobre el registro comprometido

de predicciones (`predictions.csv`, 42 predicciones de las cuales el conjunto de correlación del programa-F se declara exploratorio y sin corregir). La cobertura real por-familia del panel de máquina (no un nominal de 600) se reporta en su propia tabla.

11. Limitaciones y fronteras declaradas

- **Los priors de LLM son sintéticos.** Portan huellas de familia de modelo; solo los patrones estables entre modelos informaron las conclusiones, y el instrumento humano idéntico es el reemplazo diseñado. Ninguna cantidad `llm-elicited` fue promovida a empírica.
- **La elicitación honesta bajo gaming es el problema abierto declarado de la arquitectura;** cada motor asume señales honestas y lo dice. Los resultados del vector de planificación se sostienen condicionados a esa frontera.
- **Fronteras del modelo:** sin etapa de veto de la autoridad por-proyecto (la diferencia de capa-de-decisión tutelado/semi-abierto queda sin poner precio); los objetos de hito son cronogramas de escrow, no contratos de evidencia completos; mundos de ámbito-único (sin federación); parámetros de obsolescencia de verificación estipulados, solo afirmaciones direccionales; el instrumento de suavizado de demanda estaba sesgado por la implementación y se degrada en espera de un planificador neutral-a-la-demora (declarado, no oculto).
- **El nulo de composición-de-reputación** es a la granularidad de proyecto de este motor; economías de mayor throughput podrían componerse más rápido.
- **La calibración del status quo** se ancla a hallazgos publicados de instituciones de auditoría; las jurisdicciones difieren, y la propia regla de línea-base-calibrada del paper de arquitectura gobierna lo que «status quo» significa aquí. La planitud del titular a través de las poblaciones de *participación* es por construcción (no tiene canal de participación), y sus funciones institucionales que V no mide — la agregación de preferencias electorales, la mediación deliberativa de conflictos, la negociación distributiva, la producción de legitimidad — están fuera de la métrica y por tanto fuera de cada ratio reportado aquí. Las métricas de resultado-distributivo son el seguimiento diseñado.
- **La capa legal está por debajo del modelo, no dentro de él.** La asignación ciudadana dirige fondos a *proyectos*; la adjudicación y el pago del ejecutor corren a través del derecho de compras públicas existente (la caracterización de acto-de-asignación de la arquitectura mantiene el acto ciudadano como pre-procedimental), el desembolso condicionado por hitos se mapea sobre la práctica ordinaria de pago-por-avance, y la inhabilitación legal es derecho de cada país operando fuera de la plataforma — plenamente compatible con que la propia plataforma nunca excluya. El costo, la demora, los procesos de impugnación y las obligaciones de reserva de las compras públicas quedan sin modelar. Asimismo, los fiscalizadores de la arquitectura son su propio mercado de control, *no* los órganos de auditoría estatal constitucionalmente independientes, que permanecen sin cambios y aparecen aquí solo como fuentes de calibración; y el estatus de derecho-administrativo del desembolso condicionado-por-máquina (debido proceso, apelabilidad — la vía de denuncia es el gancho de apelación diseñado) es una pregunta abierta de despliegue apareada con el diseño humano de segunda instancia.

- **Alcance del objeto gobernado.** La mayor parte del gasto público son servicios recurrentes y transferencias; la arquitectura gobierna la porción discrecional con forma de proyecto de un presupuesto (obras de capital, subvenciones, programas locales). Cada afirmación titular debe leerse a ese alcance, con la cuota del sobre calibrada a la composición discrecional real de una jurisdicción en el despliegue.
- **Evidencia de simulación, no prueba institucional.** El programa mide un modelo. Su rol es encontrar puntos de quiebre, ordenar mecanismos y entregar a la arquitectura preguntas cuantificadas — tres de las cuales ya respondió hacia el canon de la arquitectura.

12. Conclusiones

Seis hallazgos de arquitectura sobreviven a un programa adversarial, pre-registrado y anclado conductualmente: el ordenamiento es invariante a la población y la capa por defecto es existencial; la calidad de asignación domina — descompuesta, tras una corrección de modelo forzada por la terminología, en una categorización macro (#1) y los perfiles de asignación de proyectos agregados (#2) que el motor previo había fundido — y el arreglo distribuido es robusto a la calidad de la categorización central mientras el central es frágil a ella, así que la ventaja sobre un status quo central crece ($\approx 1.9\times \rightarrow \approx 5.7\times$) a medida que empeora la planificación central; la atención es estructural y de un solo dígito; la pila de disuasión es complementos-no-sustitutos con una regla de margen-publicado como su consecuencia de despliegue; la transición es un dial; y el pipeline dinámico añade tres reglas institucionales — dimensiona la capacidad, dosifica la liberación, protege el margen — con la verificación por máquina como seguro de capacidad cuya seguridad la propia pila de disuasión respalda, y la segunda instancia humana como el auditor permanente de la máquina. Dos hallazgos adicionales se mantienen a una confianza más baja y así se dice: el panel de verificación por máquina, cuyo primer instrumento portaba un bug de constructo que una segunda ronda de revisión atrapó y cuyo resultado corregido está escalonado por capacidad y es en parte exploratorio; y el adversario colusivo, el primer ataque en mover la fuga en un orden de magnitud y la frontera en la que la historia de la verificación se rompe y este programa de autor único más necesita un segundo autor para el adversario.

Dos meta-resultados importan más allá de esta arquitectura. Metodológicamente, la combinación — contratos de trazabilidad, pre-registro con refutaciones públicas, participación endógena, calibración de priors por LLM bajo disciplina entre modelos, y docking — es una receta portable para el diseño institucional computacional. Institucionalmente, el programa demuestra un bucle de retroalimentación disciplinado entre la simulación y el diseño: los hallazgos entraron al corpus de la arquitectura a través de su pipeline publicado de ataque-defensa-resolución, con veredictos registrados. Una nota de honestidad pertenece junto a esa afirmación: la simulación, la arquitectura, el pipeline y los veredictos son el ecosistema de un solo autor — el bucle demuestra *disciplina de proceso* (los hallazgos no pueden cambiar silenciosamente el diseño; las refutaciones se publican), no validación independiente. El paso de independencia es externo: los paquetes de revisión-por-expertos preparados del paper de arquitectura y, en última instancia, el instrumento de calibración humana y un piloto acotado. Dentro de esa frontera la afirmación se sostiene: la simulación no aduló a la arquitectura; discutió con ella, refutó un tercio de sus propias predicciones en público, y forzó dos reglas de diseño que la arquitectura no tenía previamente.

Declaración de reproducibilidad

Todos los motores, escenarios, resultados, figuras (con descripciones textuales accesibles), diseños y contabilidad de predicciones están en el repositorio público, con reproducción de un-comando (`python tools/reproduce_all.py`) que cubre cada artefacto comprometido excepto los paneles de LLM, que se comprometen con procedencia completa y prompts. Código MIT, documentos y resultados CC BY 4.0.

Referencias

- Axtell, R., R. Axelrod, J. M. Epstein, and M. D. Cohen (1996). "Aligning Simulation Models: A Case Study and Results." *Computational and Mathematical Organization Theory* 1(2).
- Baiocchi, G., and E. Ganuza (2014). "Participatory Budgeting as if Emancipation Mattered." *Politics & Society* 42(1).
- Becker, G. (1968). "Crime and Punishment: An Economic Approach." *Journal of Political Economy* 76(2).
- Epstein, J. M. (2006). *Generative Social Science: Studies in Agent-Based Computational Modeling*. Princeton University Press.
- Fox, J. (2007). "The Uncertain Relationship Between Transparency and Accountability." *Development in Practice* 17(4–5).
- Holmström, B., and P. Milgrom (1994). "The Firm as an Incentive System." *American Economic Review* 84(4).
- Little, J. D. C. (1961). "A Proof for the Queuing Formula: $L = \lambda W$." *Operations Research* 9(3).
- Malesky, E., P. Schuler, and A. Tran (2012). "The Adverse Effects of Sunshine: A Field Experiment on Legislative Transparency in an Authoritarian Assembly." *American Political Science Review* 106(4).
- Milgrom, P., and J. Roberts (1990). "The Economics of Modern Manufacturing: Technology, Strategy, and Organization." *American Economic Review* 80(3).
- Milgrom, P., and J. Roberts (1995). "Complementarities and Fit: Strategy, Structure, and Organizational Change in Manufacturing." *Journal of Accounting and Economics* 19(2–3).
- Offermann, M. (2026). "Distributed Resource Governance: An Architecture for Transparent Public Resource Allocation with Adversarial Validation." Working paper, doi:10.5281/zenodo.21193846.
- Ostrom, E. (1990). *Governing the Commons: The Evolution of Institutions for Collective Action*. Cambridge University Press.
- Railsback, S. F., and V. Grimm (2019). *Agent-Based and Individual-Based Modeling: A Practical Introduction*. 2nd ed., Princeton University Press.
- Sintomer, Y., C. Herzberg, and A. Röcke (2008). "Participatory Budgeting in Europe: Potentials and Challenges." *International Journal of Urban and Regional Research* 32(1).
- Spearman, M. L., D. L. Woodruff, and W. J. Hopp (1990). "CONWIP: A Pull Alternative to Kanban." *International Journal of Production Research* 28(5).
- Wampler, B. (2007). *Participatory Budgeting in Brazil: Contestation, Cooperation, and Accountability*. Penn State University Press.